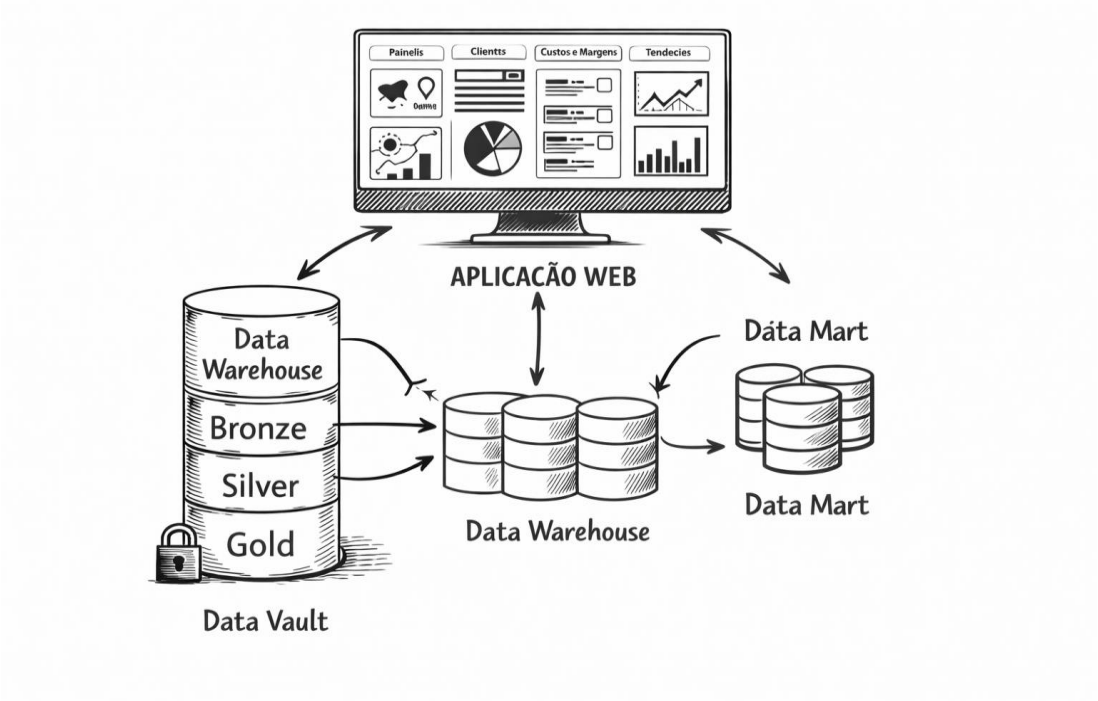
Plataforma Integrada de Inteligência Comercial com Visão Multidimensional Baseada em Dados

O objetivo desse projeto é criar uma Plataforma Integrada de Inteligência Comercial que consiga conectar todas as bases de dados da empresa de todas as áreas e transformar isso em visão estratégica 360° de forma organizada, estruturada e com logs e histórico.

Hoje a empresa possui um volume considerável de dados, o maior problema não é falta de informação, e sim a dispersão entre os dados. Temos dados armazenados em múltiplos sistemas, plataformas Sharepoint, Auvo, Omie, Granatum, XMLs, SAP etc... Ainda temos bases externas Bases externas como IBGE, Receita Federal e Geofusion.



Cada sistema cumpre seu papel operacional, mas eles não conversam entre si, e isso gera algumas complicações:

Silos de dados: Cada área enxerga apenas o seu próprio pedaço da realidade.

Divergências: Comercial, Financeiro e Operação podem ter versões diferentes da mesma informação.

Dificuldade de decisão baseada em alguma informação: Em algumas situações pode ser necessário exportar planilhas, cruzar dados manualmente e validar informações que podem estar em diversos lugares.

Então a ideia em si é não apenas criar um banco de dados, e sim uma Plataforma Integrada, que integre, todas as bases de dados de forma estruturada, organizada,

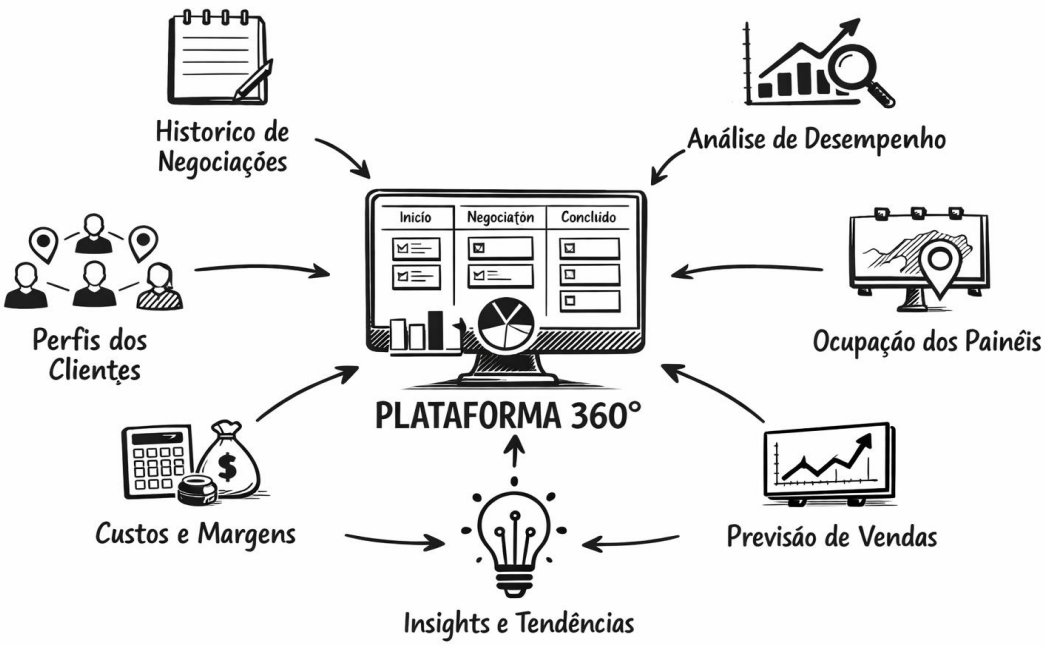
com logs, histórico e ainda ofereça segurança com a integridade, atomicidade e os dados que estão dentro dela para que não aconteça vazamento de informações. O objetivo é enxergar tudo, enxergar a empresa como um cubo, termos uma visão 360.

Isso tudo começa com a criação de um banco de dados em SQL Server que estamos desenvolvidos e aqui começa a entrar alguns conceitos novos que estamos implementando dentro da empresa, o objetivo disso é criar uma cultura orientada a dados e começarmos a digitalizar mais as coisas.

Iniciamos criando um Data Vault.

O que seria um Data Vault?

https://triggo.ai/blog/entenda-o-que-e-data-vault/



O Data Vault é uma Camada de armazenamento histórico, estruturada para manter logs, garantir rastreabilidade, preservar histórico completo de alterações e permitir auditoria dos dados, nada se perde, tudo fica registrado.

basicamente ele é feito para integrar várias fontes de dados, manter histórico completo, garantir integridade, garantir rastreabilidade, permitir o crescimento sem quebrar a estrutura do que está sendo feito.

Ele organiza o mundo em 3 blocos:

HUBS: que são as identidades principais, por exemplo o Cliente, Painel, Contrato, Segmento etc...

LINKS: são os relacionamentos Cliente ↔ Contrato, Contrato ↔ Painel, Painel ↔ Região

SATELITES: Históricos e atributos, como Status, Valores, Perfil, Custos, Ocupação, Características.

O Data Vault não é feito para visualização a ideia dele é outra, ele é feito para organização estrutural e integridade ele é o Coração da Integração.

E está sendo criado a parte estruturada para visualização dos dados e analises, no caso o **Data Warehouse,** aqui os dados deixam de ser registros isolados e passam a ser organizados em fatos, dimensões, métricas, relacionamentos.

antes é necessário como funciona o fluxo para a ingestão e atualização incremental dos dados.

Fontes → Ingestão → Bronze → Data Vault → Silver → Gold → Data Marts → Aplicações / BI

Foi definida uma arquitetura estruturada em camadas

Durante a extração e tratamentos dos dados para a ingestão, que chamamos de ETL, os dados vem de suas diferentes fontes, isso é feito através de pipelines criados em Python. Após extrair, padronizar etc... ele carrega os dados no banco de dados seguindo a lógica de camadas do modelo arquitetural.

No projeto de banco de dados, temos as camadas **Bronze**, **Silver**, **Gold**. Após a extração os dados são carregados na camada **Bronze**, nessa camada eles entram praticamente da mesma forma da sua origem, eles vem brutos.

Após a **Bronze**, as pipelines executam as transformações técnicas necessárias e carregam os dados na camada Silver.

A partir da Silver, os dados alimentam o modelo **Data Vault**, que é responsável pela preservação histórica e pela governança.

O processo funciona da seguinte forma:

As entidades principais são inseridas nos **Hubs** (**ex.: Cliente, Painel, Contrato, produção**).

Os relacionamentos entre entidades são registrados nos **Links**.

Os atributos descritivos e mudanças ao longo do tempo são armazenados nos **Satellites**.

O Data Vault não sobrescreve dados. Toda alteração gera um novo registro. Isso garante um histórico completo, permite auditar e reconstrução a partir de cenários passados, essa camada é fundamental para manter a integridade e rastreabilidade.

Durante essa etapa são criadas as tabelas de Dimensão e as tabelas de Fato, e aqui passam a existir as regras de negócio consolidadas e cálculos estruturados.

Existir ainda a camada Gold, que contém os dados já tratados e organizados para consumo final.

Camada Bronze: primeira camada de armazenamento dentro do banco após a extração. Aqui vão os dados brutos.

Camada Silver: Aqui os dados deixam de ser “crus” e passam a ser tecnicamente confiáveis. Eles recebem alguns ajustes, a Silver é o que alimenta o modelo estruturado (Data Vault ou diretamente o DW).

Camada Gold: É a camada usada para analises, aqui os dados estão tratados normalizados, padronizados, podemos dizer que estão sem sua forma final.

Dentro do conceito de Data Warehouse, existe um outro conceito que são as tabelas de **Fatos** e **Dimensões**.

As Tabelas de Fato contém os eventos mensuráveis, valores numéricos, métricas, podemos dizer que é o fato em si.

As tabelas de Dimensão são basicamente o contexto descritivo, elas meio que respondem a perguntas como, **de quem ?, de onde?, quando ?, qual categoria ?** etc...

e ainda temos os **Data Marts**, o Data Mart basicamente é uma visualização temática ou podemos dizer uma subárea especializada do Data Warehouse. É o mesmo que pegarmos um pedacinho o DW e dedica-lo a um assunto especifico, área especifica, exemplo comercial, financeiro, produção etc...

Entendendo isso, fica fácil imaginar a coisa toda funcionando. Basicamente teremos o servidor, dentro dele os scripts python, que chamamos de pipelines, eles ficam sendo executados diariamente, a frequência nós decidimos e a cada execução ele puxa os dados da fonte e faz a atualização incremental no banco de dados.

A grande vantagem disso tudo é que quando se precisa por exemplo consultar o contas a pagar, receber, verificar se por exemplo uma medição foi feita ou paga, verificar, checar a ocupação de um painel, é necessário verificar em algumas fontes de dados, confirmar com alguma outra pessoa, então acaba que não sendo tão simples, e rápido. Se for algo então que precisa ver no Omie ou Granatum, e que precisa acessar os ambientes de outras empresas, ou então fazer um DRE, é preciso repetir o processo algumas vezes. Então é justamente ai que entra o objetivo do banco de dados, a ideia dele é eliminar a fragmentação, e esse trabalho de buscar, conferir, normalizar etc... é totalmente abstraído pelos scripts python, então no final o usuário vai ter o acesso direto a informação, seja na tabela do banco de dados, no excel, power BI etc...

Outra vantagem é a possibilidade de ter uma visão micro e macro dos dados ao mesmo tempo, permitindo uma análise ampla e estratégica apenas cruzando algumas tabelas.

Por exemplo, quando um vendedor está negociando com um cliente para fechar contrato em determinado painel, ele pode consultar o cadastro completo do cliente,

analisar a região onde está o painel ou a região de atuação do cliente, verificar o segmento do cliente, analisar tempo de relacionamento, valores negociados, ativos contratados, entre outras informações.

Ao cruzar todos esses dados, o vendedor passa a ter uma visão completa da situação. Ele consegue enxergar tanto o contexto macro (perfil da região, comportamento do segmento, histórico geral) quanto o micro (detalhes específicos daquele cliente e daquele painel).

Além disso, o acesso às informações se torna simples e rápido. Se o painel desejado pelo cliente estiver sem disponibilidade, o sistema já permite visualizar imediatamente quais outros painéis estão disponíveis na mesma região ou com características semelhantes, facilitando a negociação e aumentando as chances de fechamento.

A ideia inicial era criar o banco de dados e estruturar as informações. Porém, percebemos que não bastava apenas armazenar os dados era necessário ter uma interface que permitisse acessar, interagir e também inserir novas informações de forma organizada e prática.

Diante disso, tornou-se necessário desenvolver uma aplicação web utilizando Python e Flask. Essa aplicação está conectada diretamente ao SQL Server, o que significa que todas as informações exibidas nela vêm do banco de dados, por meio de consultas realizadas sobre suas tabelas. Com isso, atualmente já conseguimos, por exemplo visualizar a ocupação de uma face de painel em determinado período de tempo, ver a disponibilidade futura e realizar reservas, consultar o histórico completo de um cliente, painel ou face ao longo do tempo

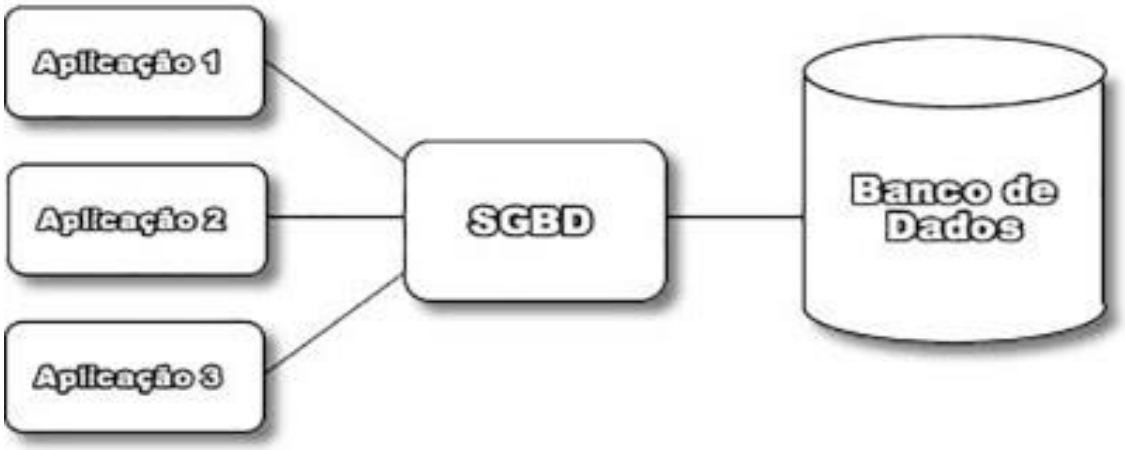
E a evolução do sistema já prevê novas funcionalidades, como Visualização de custos e margens por contrato, histórico de ocorrências e chamados relacionados aos painéis que hoje são integrados ao Auvo, Análise de margem por contrato, Identificação de segmentos que performam melhor em cada painel, analise de compatibilidade entre segmentos, Visualização de empresas em um raio de 10 km ao redor do painel, Análise do perfil dessas empresas, Identificação de concorrentes na região, Monitoramento de atrasos de pagamento por parte dos clientes (já existe uma tela para isso, porém a evolução dela, será permitir que o financeiro consiga interagir com ela). Tudo isso está sendo integrado a partir de múltiplas fontes, como planilha de contratos, Granatum, Apis do Omie, Bases de dados do IBGE, Receita Federal, Geofusion etc... O resultado é um ecossistema unificado de dados, que transforma informações dispersas em dados estruturados.

Uma evolução importante desse projeto ocorreu com o Cadastro de Empresas e Clientes. Antes, as informações estavam fragmentadas em diversas fontes de dados, o que dificultava análises consistentes e estratégicas. Iniciamos então um processo de unificação dos cadastros, realizando também o enriquecimento das informações, por meio da integração com dados da Receita Federal. Além disso, foi feita a classificação, padronização e segmentação dos clientes, garantindo consistência estrutural e qualidade nos dados. Hoje, já é possível visualizar Perfil comportamental dos clientes, público-alvo, histórico de contratos, relacionamento ao longo do tempo, Segmentação estruturada e padronizada, ainda teremos uma

segunda etapa do projeto, iniciamos o desenvolvimento de algoritmos de Machine Learning, que serão utilizados para identificar a correlação entre clientes e painéis, gerar scores de similaridade entre clientes, identificar padrões etc....

E outra evolução foi em relação aos painéis começou a ser construída uma tela que é chamada de Ativos, nela podemos ver todas as informações do painel, componentes que formam ele, custos desses componentes. Custos do painel, custos mensal, retorno do painel, histórico de rentabilidade, receita, podemos inclusive nessa mesma tela, adicionar outros painéis e comparar eles, tem até um gráfico de serie temporal onde temos essa visão e comparamos o painel, vários painéis a ideia é nessa tela colocar os ativos da empresa, como por exemplo as carretinhas etc... e comparar isso, ainda nessa tela esta sendo adicionado e criado índices que poderemos comparar como **CDI**, **SELIC**, **histórico de outras empresas do segmento**, **índices de consumo**, **imobiliário**, **índices de setores** que façam sentido, tudo isso para ver e termos uma espécie de benchmark "**como se fosse uma régua**" e assim ser possível comparar. E Nessa mesma tela irá exibir alguns gráficos para auxiliar a ter uma visão disso, gráfico de rentabilidade, custos, ainda terá todas as ocorrências que o ativo possa ter tido que virá do auvo (uma parte da integração já foi criada). E tudo isso de forma muito simples, intuitiva e a apenas a alguns cliques de distância, toda a complexidade é abstraída pelos backends que foram criados e estão sendo desenvolvidos... O usuário irá ter a visão da tela final.

Isso tudo é feito em cima do banco de dados que estamos criando, com toda aquela estrutura.

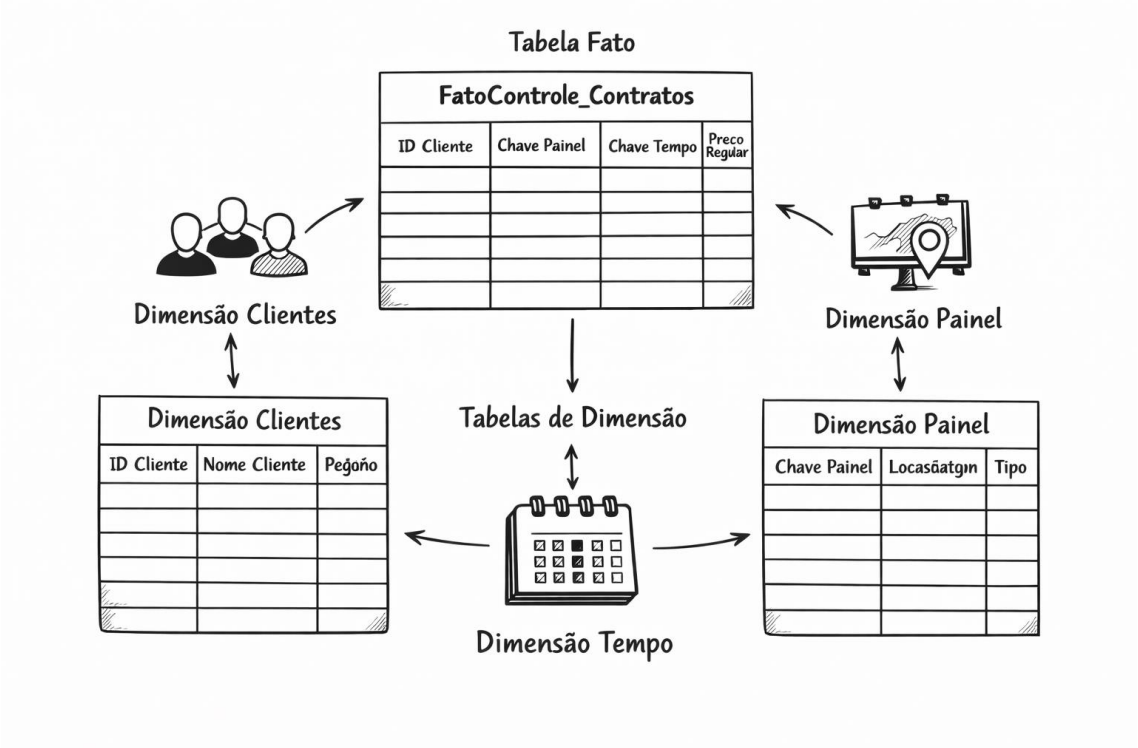


O objetivo de tudo isso é responder as perguntas que se possam ter a respeito do negócio, e também para o time comercial, no caso Euromidia, auxiliar e ser uma espécie de apoio que auxilia a dar até mesmo poder argumentativo estruturado, em momentos de negociação durante um atendimento por exemplo, pois sempre tem aqueles clientes que fazem umas perguntas complicadas que no momento é difícil de lembrar as repostas na correria do dia a dia.

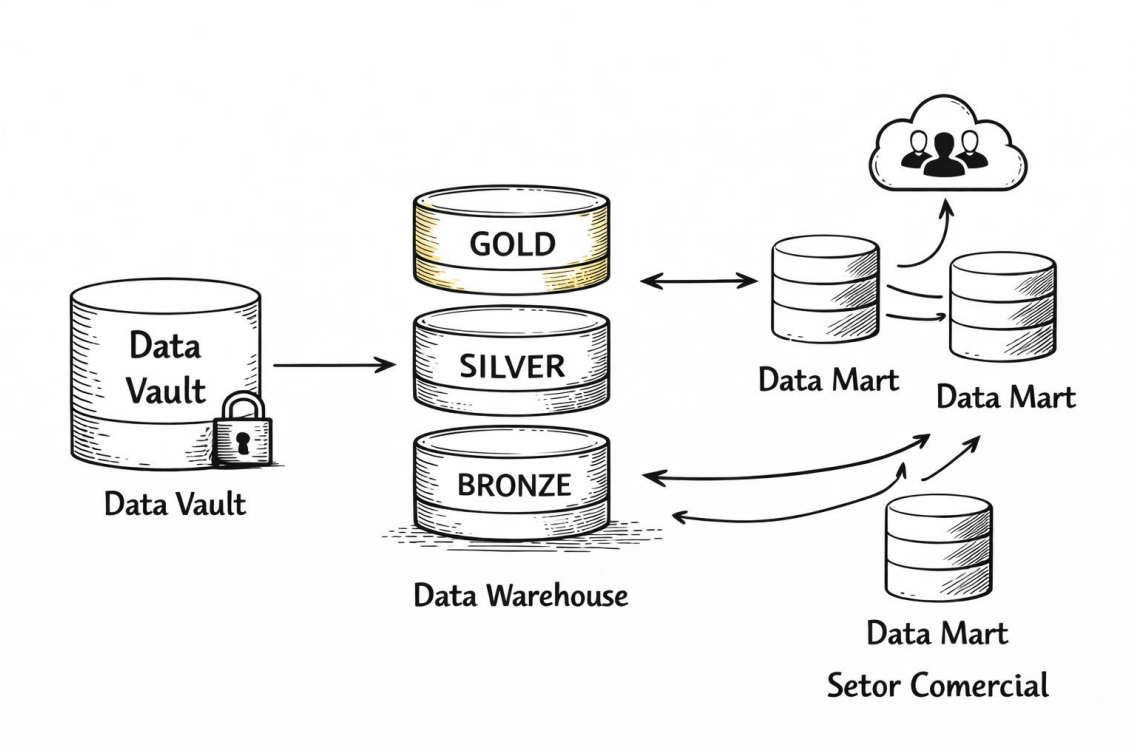
A plataforma vai auxiliar a conduzir o raciocínio estratégico, sugerir perguntas certas, sugerir argumentos baseados em dados, antecipar oportunidades, ajudar a prever o melhor momento de abordagem.

Isso aumenta a visão em cima do todo, vamos assim dizer, e a pessoa passa a enxergar o painel, componentes que formam ele, custos, margens, regiões, empresas, segmentos, perfil das empresas, perfil das regiões, qual empresa tem maior compatibilidade com qual painel, com quanto tempo de campanha, isso fica melhor em qual região, quais regiões, concorrentes, quais características do painel, qual diferença entre um e outro, padrões, histórico etc...

Um vendedor por exemplo ele passa a atacar mais vamos dizer assim e consegue responder qualquer pergunta a qualquer momento e muitas vezes por mais inusitadas que as perguntas possam ser. E tudo baseado em dados, em cima das tabelas Fato, dimensões.



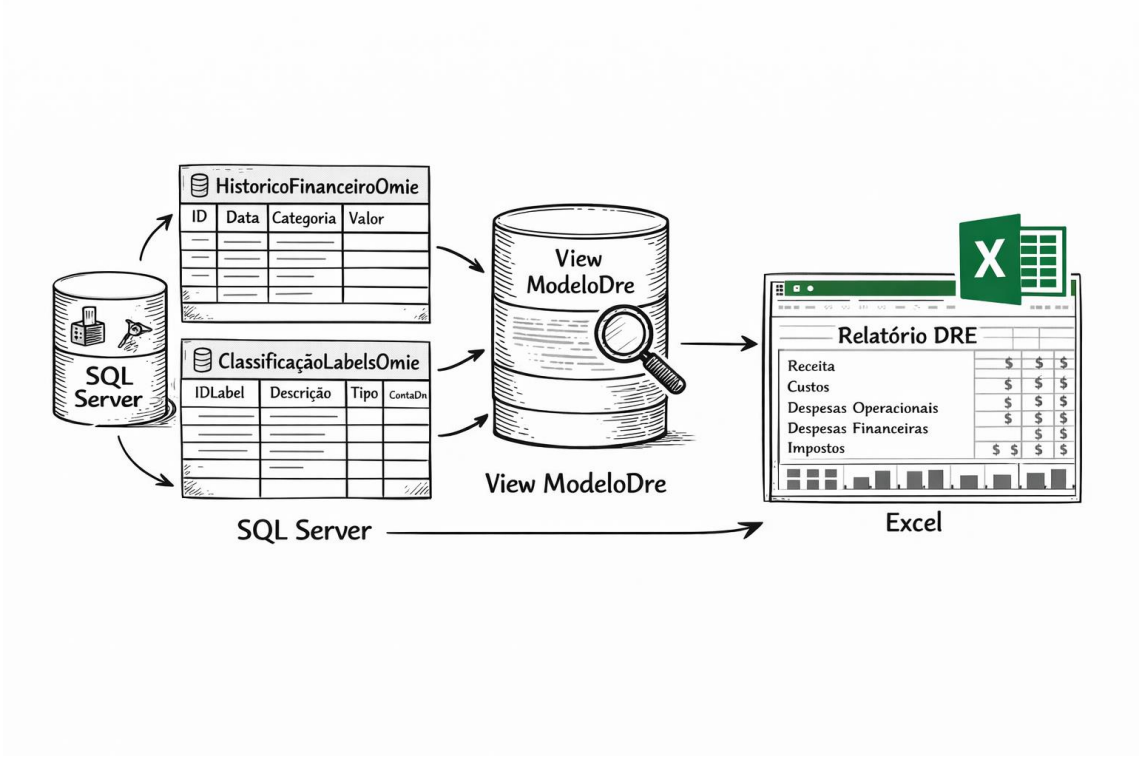
Tudo feito seguindo um fluxo estruturado, onde toda a informação percorre.



Olhando assim, pode até preocupar, pensar que deve ser complexo, a pessoa para usar precisa saber programar etc... Porém o melhor de tudo isso é que não é necessário mudar nada na rotina.

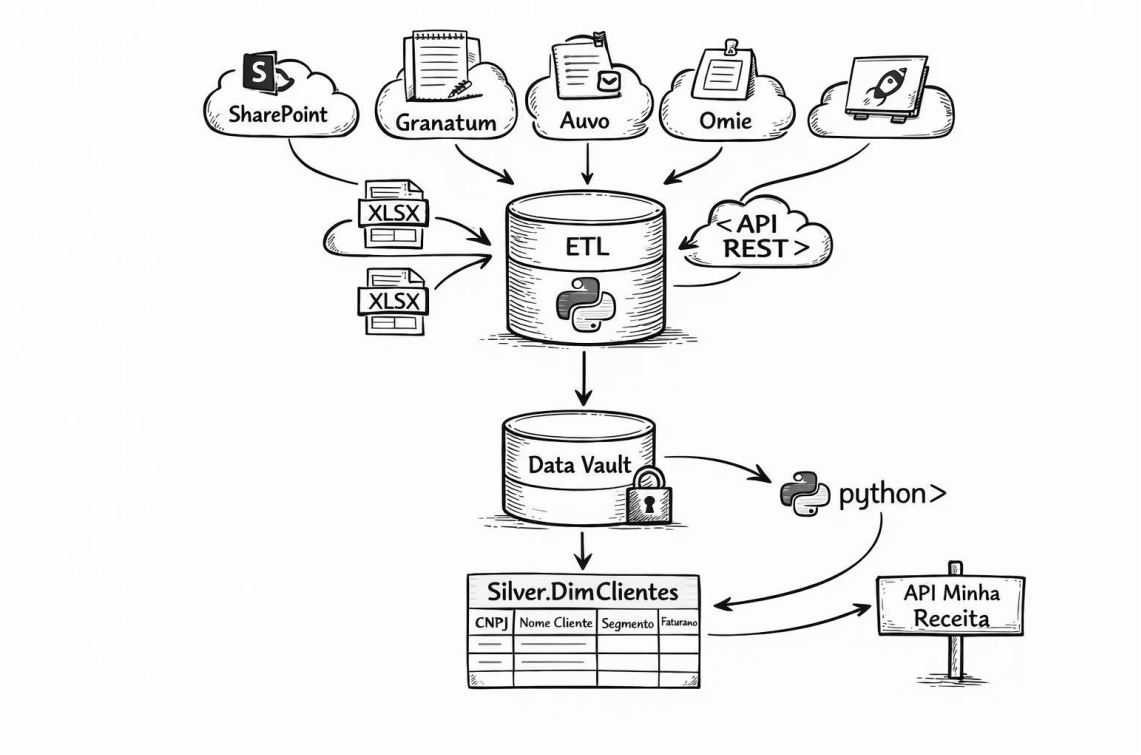
A complexidade é totalmente abstraída pelo **backend**,conforme foi dito toda a parte de integração dos dados, limpeza dos dados, logs, atualização incremental, integridade e atomicidade fica com o **backend**, o usuário não terá acesso a nada disso, nem é necessário. E por exemplo quem usa **excel**, poderá continuar usando o **excel**, bastando apenas conectar o **excel** com um usuário e senha ao banco de dados, a pessoa terá a visão das telas, e as tabelas são super simples, o layout delas é muito semelhante a uma tabela do **excel**. E o banco de dados por ser SQL Server a integração é facilitada com as ferramentas que usamos por ser tudo da Microsoft.

Por exemplo para fazer um DRE, antes precisaria extrair **excel**, e ajustar ele e esse **excel** vinha de varias ferramentas. Com o banco de dados, já temos uma tabela de classificação das **labels** e os históricos que vem da api do **Omie**, logo com uma consulta que pode ser colocada no **excel**, basta clicar em atualizar dados e o **excel** já puxa tudo do banco de dados...



O usuário irá ter a visão de tabelas com nomes muito intuitivos, e por trás dessa simplicidade existe toda uma estrutura integrada.

Ou seja, teremos uma visão **360**, em tempo real. Histórico estruturado, correlação cruzada, experiencias e repostas conduzidas por evidencias e aqui começa a entrar alguns novos conceitos ML (**Machine Learning**).

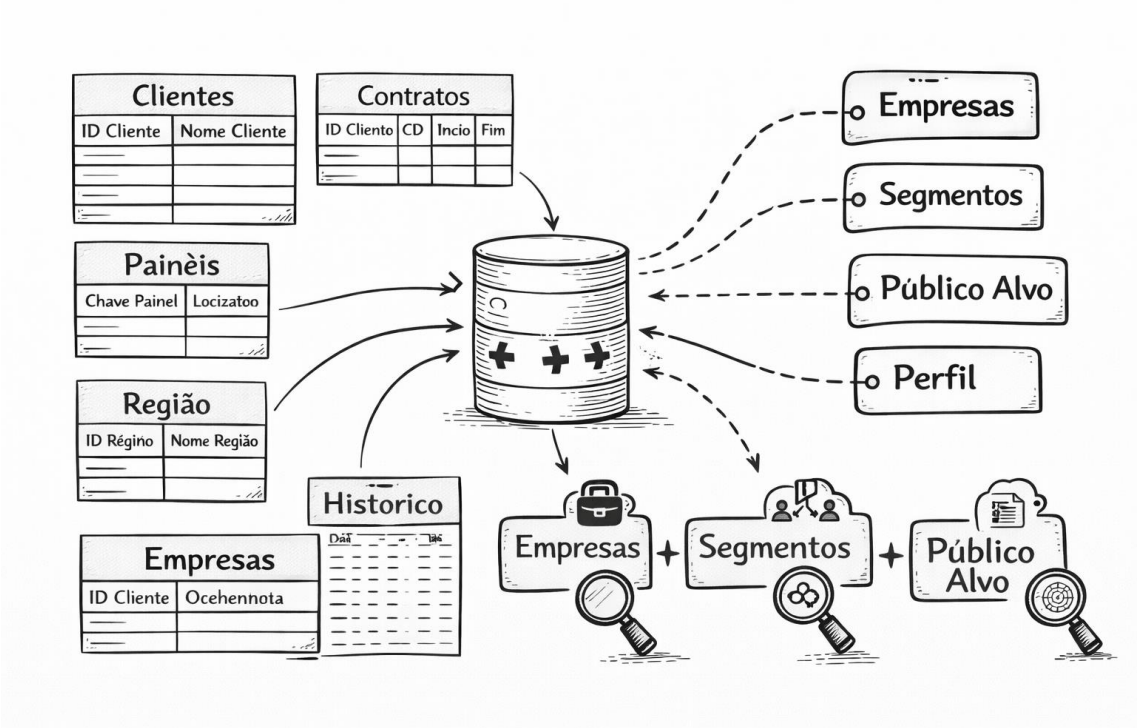


Porém ao relacionar essas bases e começar as primeiras analises fazendo os cruzamentos com as tabelas do DW, foi possível perceber algumas coisas. Os dados revelam muitos padrões, como comportamento de compras, padrões de segmentação, regionais, temporais

Começamos a relacionar isso com o Controle de contratos da **Euromidia**, e ao fazer as primeiras analises, foi possível começar a perceber alguns padrões em relação as vendas, painéis, regiões, segmentos e histórico... Os dados, de certa forma começavam a revelar padrões.

Cruzando Cliente + Contrato + Painel + Região + Segmento + Histórico

Começamos a fazer classificações, criar labels para empresas, segmentos, público alvo, perfil.



E uma coisa vai levando a outra e percebemos que precisávamos enriquecer mais essas bases, aumentar a granularidade para entender mais os padrões, adicionar camadas externas de informação para interpretar melhor o comportamento.

E com isso começamos a nos fazer varias perguntas...

Por que alguns clientes compram muito e outros compram pouco?

Por que alguns compram uma vez e param?

Existe churn?

Podemos recuperar clientes perdidos?

Por que alguns clientes compram de forma diversificada e depois interrompem?

Existe sazonalidade?

A época do ano influencia?

A região do painel influencia?

Existem mais empresas que podemos abordar naquela região?

Por que um cliente compra da gente e do concorrente?

Por que ele prefere um painel ao invés de outro?

Quando é pertinente oferecer mais painéis?

Quando é melhor reduzir?

O momento macroeconômico influencia?

O público-alvo tem correlação com a região?

A faixa etária da região faz diferença?

Regiões com maior concentração de famílias tendem a performar melhor para campanhas educacionais?

Regiões com população mais envelhecida têm maior correlação com planos de saúde?

Se um cliente pedir sugestão de região, temos base para indicar?

Se ele perguntar tempo ideal de campanha, conseguimos justificar?

Se ele perguntar se é melhor painel digital ou empena, conseguimos argumentar?

Se ele perguntar sobre características técnicas como brilho, tamanho ou visibilidade, conseguimos contextualizar com dados reais?

Será que existem outras regiões que ainda não temos painéis, e são boas e poderíamos explorar?

Será que existem outras empresas com perfis compatíveis e poderíamos explorar? Se sim quantas seriam?

As empresas que contratam por exemplo os painéis da Euromida elas estão a qual distancia do painel por exemplo? A distância faz a diferença?

será que algum vendedor é melhor para atender a algum tipo de perfil de cliente em especifico?

E essas perguntas começam a elevar o nível da coisa, e logo pensamos, podemos já ter tudo isso estruturado? Antecipar repostas? E termos uma visão multidimensional de tudo isso? Pois de certa forma uma coisa está ligada a outra. E para isso é necessário ampliar muito o contexto.

E foi aí que começamos a incorporar novas bases externas.

Começamos a explorar bases do **IBGE**, **Receita Federal**, **Gov**, **Geofusion**:

CNEFE: Cadastro Nacional de endereços para fins Estatísticos (Base com todos os endereços georreferenciados do Brasil). Permite saber onde existem domicilias, tipos de domicílios residenciais, não residências, latitude, longitude, logradouro, cep etc...

GPKG (Geopackage): Isso pode ser usado até para criar ferramentas de GPS, é um arquivo Geospacial, ele contem mapas de bairros, setores censitários, limites geográficos, camadas espaciais. (Permite cruzamentos geográficos precisos, analises espaciais, calculo de raio, sobreposição de camadas).

Agregados por Setor Censitário: Dados agrupados por pequenas divisões territoriais, inclui renda média, faixa etária, escolaridade, numero de moradores, tipos de domicilio, isso da profundidade demográfica.

Agregados por Bairro: Informações consolidadas por bairro, perfil populacional, renda média, densidade, características socioeconômicas.

Receita Federal Estabelecimentos: Todos os CNPJs ativos, cnaes, Endereço, situação Cadastral. Permite saber todas as empresas da região, segmentos da região, identificar segmentos dominantes, medir potencial de prospecção.

Geofusion: Nos dá um grande potencial, ainda precisamos explorar mais, nos do potencial de consumo, classificações regionais, poder aquisitivo estimado, dados mercadológicos muito ricos.

Porém, apesar de começar a ter feito algumas analises iniciais, tem um grande fator que limita, e impede de explorar todo o potencial disso. Essas bases reunidas consomem vários gigabytes de dados.

Estamos falando de milhões de CNPJs, milhões de endereços, coordenadas latitude e longitude, camadas geográficas. Dados demográficos detalhados e além disso a grande quantidade de dados que vão ser gerados ao fazer os cruzamentos entre todas essas bases, classificações etc... Por isso a necessidade de um servidor dedicado que tem grande quantidade de Ram, armazenamento, processamento etc...

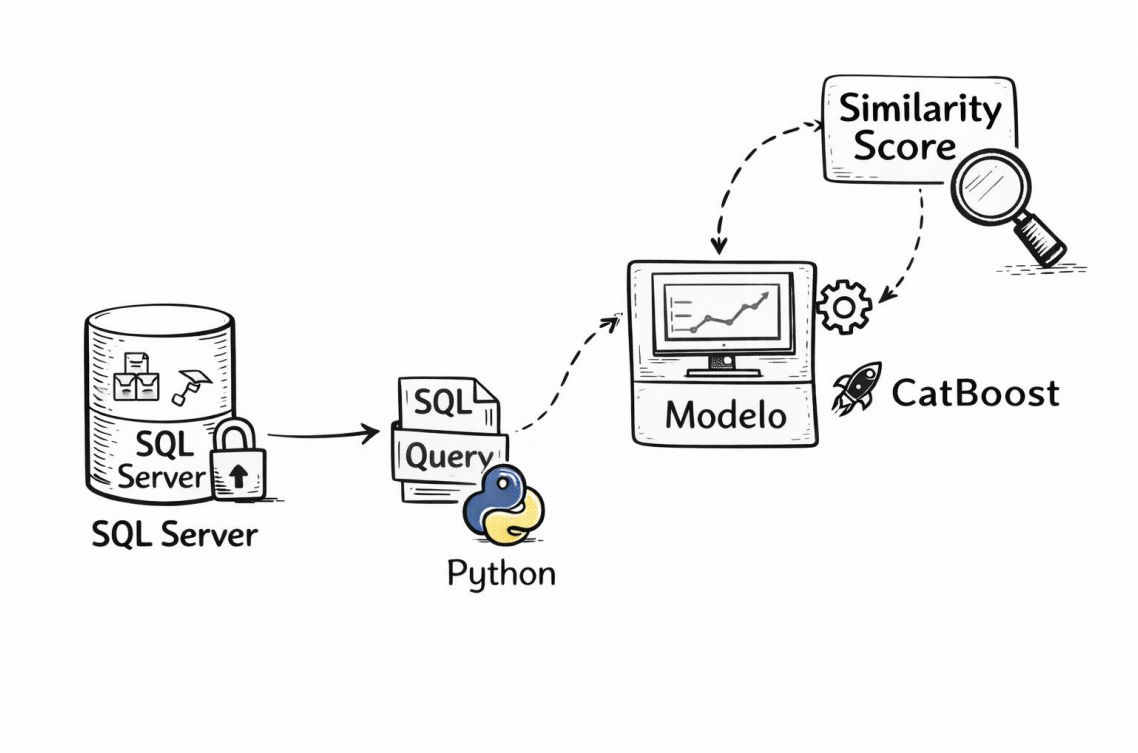
A partir disso, começou a entrar novos conceitos no nosso projeto como.

Estatística, Machine Learning, **Geomarketing**. Nas analises iniciais, começamos a entender algumas coisas.

As variáveis se movem juntas? Comportamento típico, sazonalidade (influência do tempo), tendencias.

E aqui começamos até a começar a fazer uso de IA. Quando falamos em IA, muitas pessoas imaginam algo como **ChatGPT**, **Gemini** ou **Copilot**. Não é isso o que estamos fazendo. O que estamos fazendo é aplicando uma abordagem especifica dentro do conceito de IA, ou seja, **Machine Learning Supervisionado** aplicado a dados estruturados. E com isso quero deixar claro que nenhum dado nosso é enviado a ferramentas externas como **GPT, COPILOT**, **GEMINI** etc... Nenhuma informação vai sair da empresa, ninguém de fora terá acesso aos nossos dados, bases de treinamento, tudo é processado internamente, são informações confidenciais e estamos trabalhando com dados proprietários e modelos treinados internamente dentro dos nossos critérios e objetivos, então é seguro, controlado e privado.

O primeiro teste que começamos fazer ou **o Similarity Score** e para esse primeiro experimento usamos um algoritmo de machine Learning chamado **CatBoost**.



O **CatBoost** é um modelo de **Gradiente Boosting**, baseado em arvores de decisão.

Aqui da uma visão do que é o **CatBoost**:

https://medium.com/data-hackers/entendendo-catboost-um-guia-quase-definitivo-b28bc153a78

E com ele, montamos a nossa base de treinamento, que foi gerada com 1795 variáveis decorrentes do cruzamento das diversas bases de dados que temos.

O conceito de **Similarity Score** é basicamente:

Um número que responde à pergunta:

“Essa empresa se parece com as empresas que já compraram com a gente?”

Ela não mede probabilidade direta de compra, ela mede afinidade de perfil... é como um termômetro de semelhança. Isso é muito útil para nos ajudar a entender o perfil dos nossos clientes e além disso para vermos se outras empresas tem um perfil semelhante com nossos “clientes” e com isso, começarmos a explorar isso e tentarmos trazer novos clientes.

Esse algoritmo não compara com uma empresa especifica, ele compara com o conjunto de dados de compradores e demais informações que temos, o algoritmo ele aprende com a base de dados que é enriquecida com todas as bases que temos, histórico, perfil, região etc... Ele analisa e aprende com tudo, com toda a granularidade encontrada, nos mínimos detalhes... E quanto mais features damos para ele, mais preciso ele fica, mais ele aprende.

Cada feature representa uma característica específica da empresa ou do contexto onde ela atua. Ou seja, transformamos dados antes brutos em variáveis explicativas.

Nessa base de dados temos informações da empresa, histórico, cidades onde a empresa já anunciou, perfil socioeconômico das regiões, indicadores temporais (recência, últimos 12 meses etc)

Depois de todos os cruzamentos e agregações obtemos um dataset com 1795 variáveis “colunas do dataset” uma dimensão para cada característica.

todas geradas através do cruzamento com várias outras tabelas e classificações que fomos fazendo, tudo isso para conseguirmos explicar todo o contexto para o algoritmo de forma que ele compreenda bem as coisas e não faça distorções.

Em cima dessa base de dados o algoritmo tenta compreender o quão dentro do território de compradores “Nossos clientes” a empresa que ele está avaliando se encontra. O score que ele cria, não é algo absoluto tipo 70 pontos, 80 = a Y etc... Ele é relativo ao nosso universo, o universo do modelo que estamos criando.

Vamos imaginar que cada empresa da nossa tabela é um ponto em um espaço multidimensional, formado pelos campos **CNAE**, **Cidade**, **Bairro**, **Ticket**, **frequência**, **perfil socioeconômico da região**, **histórico** etc...

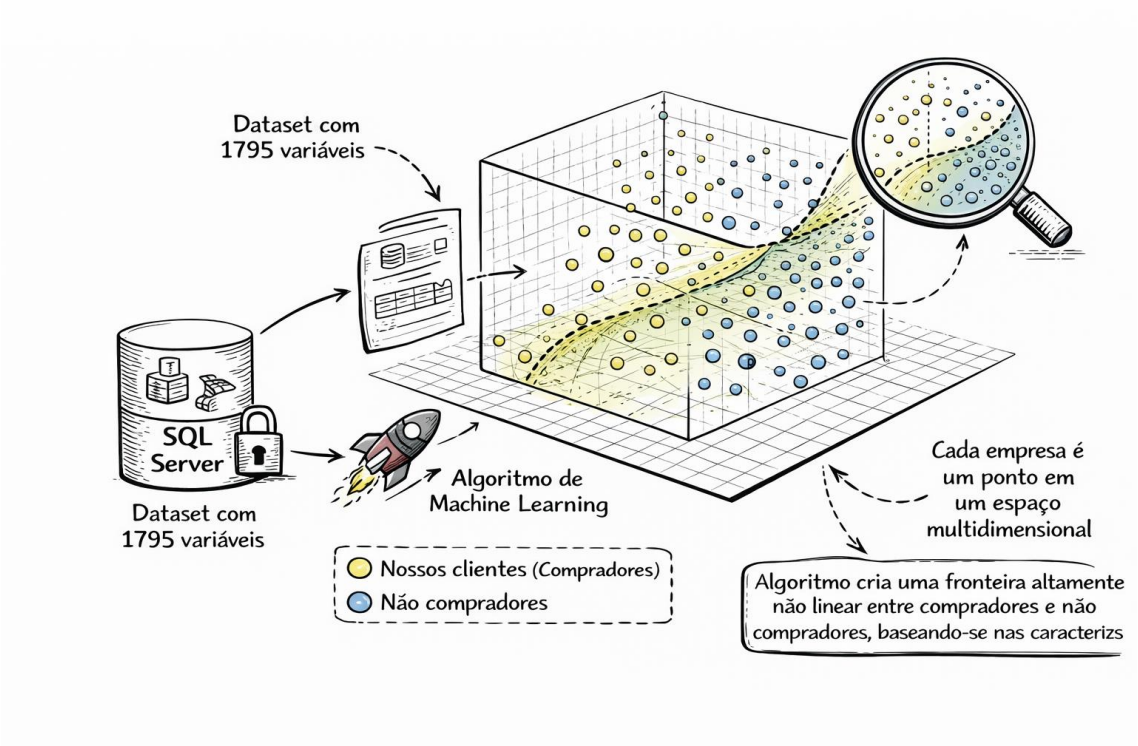
Vamos pensar que cada empresa vira um ponto em um espaço como 1745 dimensões, sendo uma dimensão para cada característica.

Então quando marcamos 1, 0 basicamente estamos pintando esses pontos de duas cores, alguns pontos começam a formar um padrão e aí é que fica interessante, com isso começa a ser fácil perceber que compradores se concentram em certas regiões desse espaço e não compradores ficam mais espalhados ou em outra área.

E com isso o nosso algoritmo cria uma espécie de fronteira que separa quem tem o perfil de comprador e quem não tem perfil de comprador. Essa fronteira não é algo tipo uma linha simples, é uma superfície altamente não linear.

Então partindo dessa analógica, podemos entender o seguinte, quando a empresa está muito do lado do comprador o score é alto, quando está distante do comprador o score é baixo, e próximo da fronteira o score é intermediário “**Médio**”

Não podemos confundir isso com probabilidade de comprar ou não comprar, o que está sendo avaliado é o perfil, características.



Além do **Similarity Score,** começamos a testar outra abordagem para entender o perfil e comportamento dos clientes, começamos a testar **Clusterização**. Todas essas abordagens são usadas em conjunto, não estamos testando uma coisa para ver se funciona e se não der certo testamos outra, nesse caso, sabemos o que queremos, e como fazer, o que estamos fazendo quando digo teste é validar a base de dados e os resultados obtidos através dela.

Nesse caso da Clusterização, usamos um outro algoritmo de **Machine Learning**, o **K-MEANS**.

Antes de mais nada a Clusterização é um método estatístico, não supervisionado, que serve para identificamos padrões naturais de agrupamento nos dados, ou seja ele usa as características que tem na nossa base de dados e com isso agrupa o que tem semelhança, não existe rótulo de certo ou errado, ele identifica padrões naturais de agrupamento.

Basicamente a lógica que usamos foi a seguinte.

Dentro do cadastro de empresas, criamos uma tabela derivada dela, a de cnaes e nessa tabela de cnaes criamos diversas classificações.

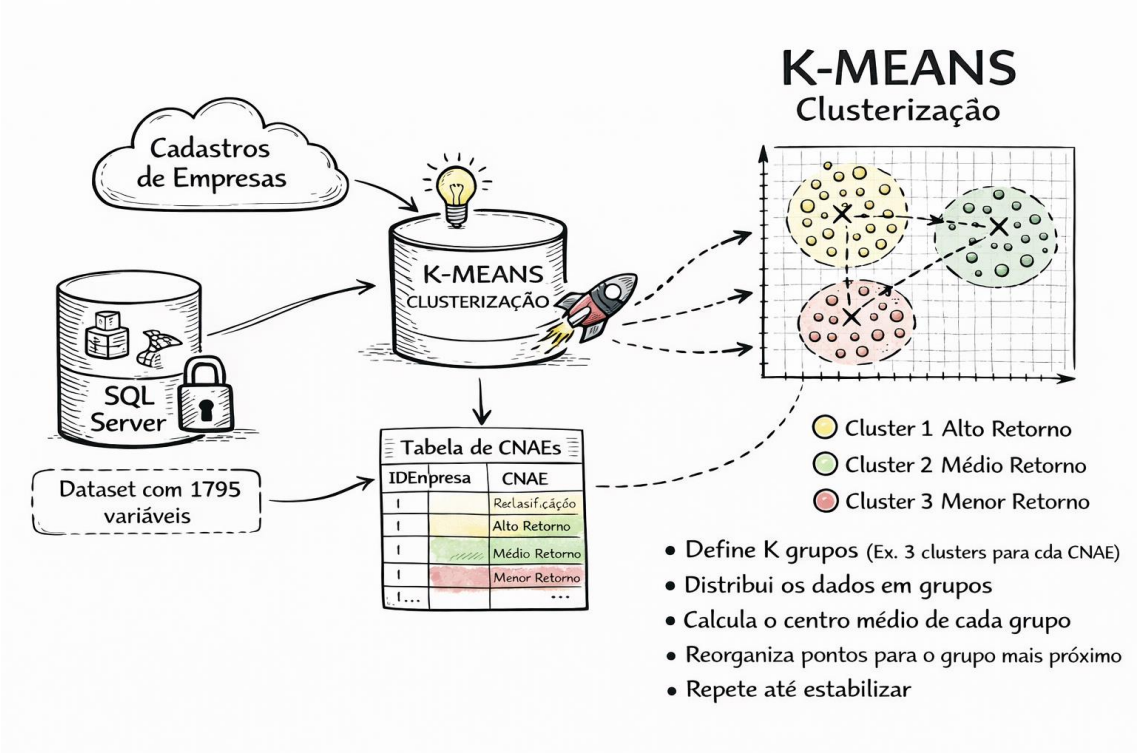
Nosso objetivo era identificar padrões dento dos segmentos e com isso fizemos o seguinte, dentro de cada cnae queríamos criar 3 Grupos **ALTO RETORNO**, **MÉDIO RETORNO**, **MENOR RETORNO**, para o **Kmeans** esses grupos são os clusters.

Definimos K grupos no nosso caso 3, para cada **cnae**.

O algoritmo distribui os dados em grupos.

Ele calcula o centro médio de cada grupo.

Reorganiza os pontos para o grupo mais próximo.



Repete até estabilizar

em resumo é isso

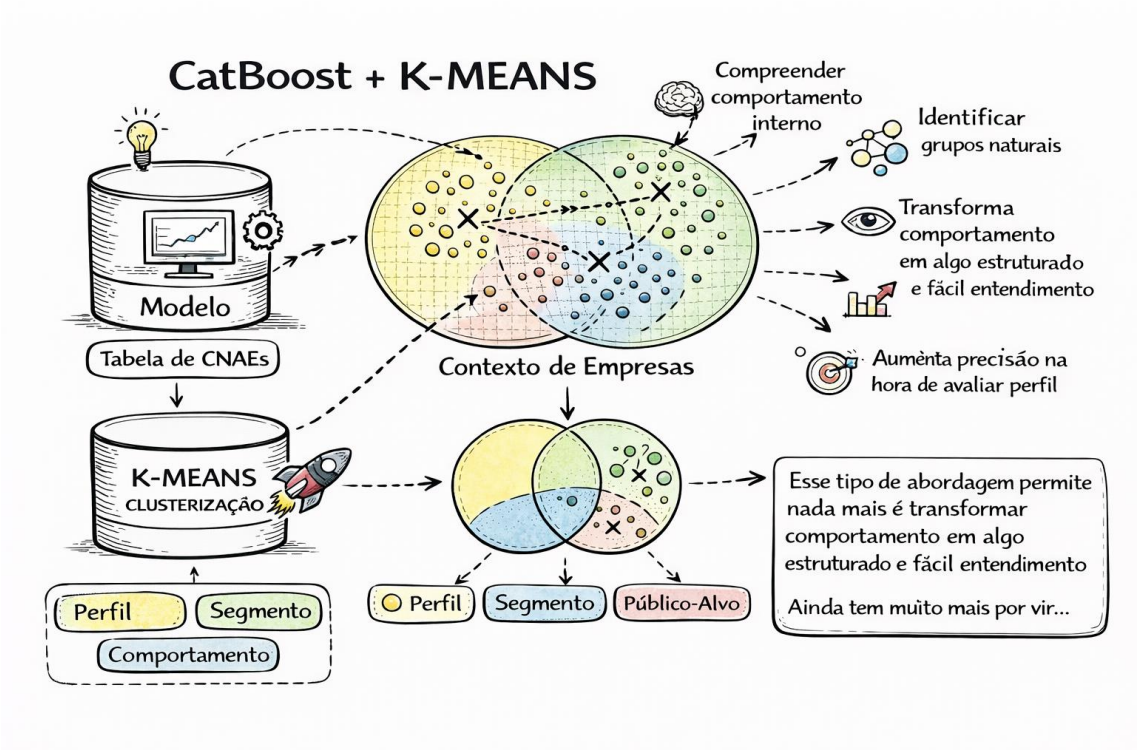
Aqui uma visão do que é o **Kmeans**:

https://www.devmedia.com.br/data-mining-na-pratica-algoritmo-k-means/4584

Entenda que por exemplo um cliente pode ter ticket alto, mais frequência baixa, outro pode ter ticket médio, mas recorrência alta, nesse caso qual seria o melhor? Sem contexto comparativo é difícil saber, a clusterização cria um referencial interno, esse é apenas um exemplo muito simples e resumido do uso do **kmeans**.

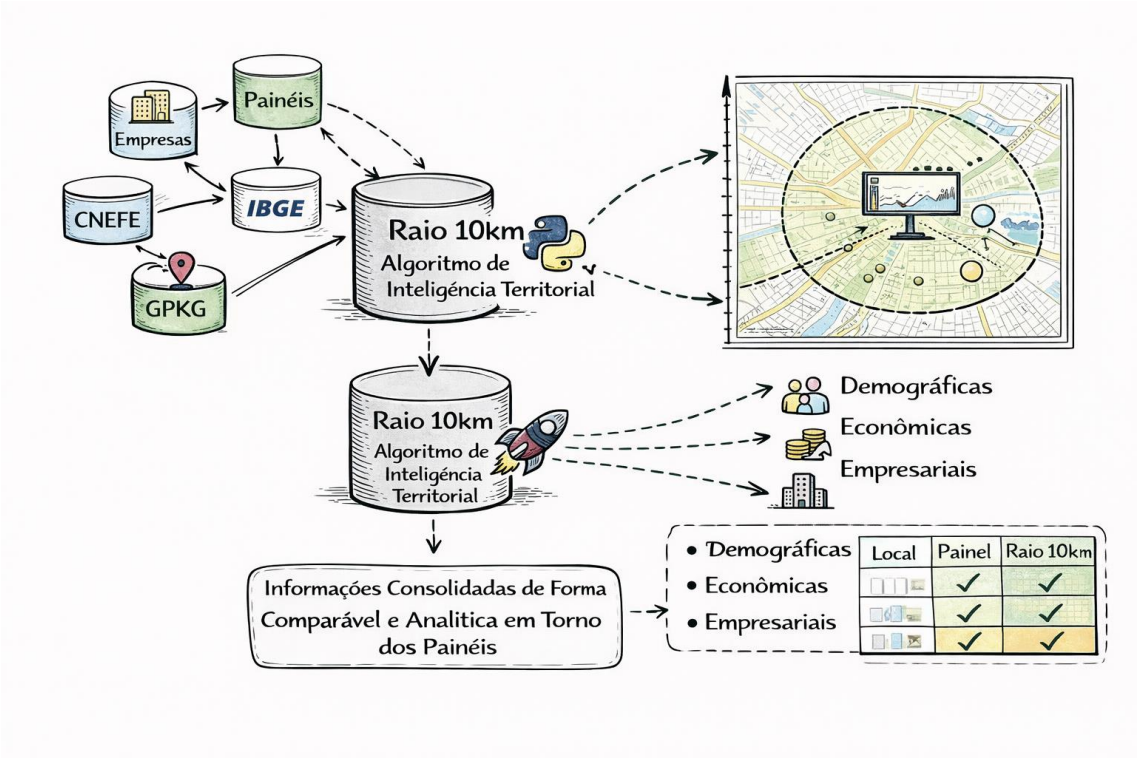
No caso a combinação desses 2 algoritmos dentro do contexto de empresas, nos ajuda a entender comportamento interno, identificar grupos naturais, enxergar padrões ocultos, mostrar posicionamento competitivo, auxiliar na prospecção, identificar afinidade, ajudar direcionar abordagem. E assim reduz subjetividade, cria segmentação baseada em dados, transforma comportamento em algo estruturado e fácil entendimento, aumenta a precisão na hora de avaliar um perfil.

Ainda criamos classificações de perfil, segmento, publico alvo, comportamento etc... Esses algoritmos foram apenas um complemento, o uso desse tipo de abordagem ainda pode ir muito mais longe.



Ainda fizemos mais alguns testes. Um deles foi na hora de fazer o cruzamento das bases de **Empresas**, **painéis**, **CNEFE** e **GPKG**. A ideia é que além dos primeiros algoritmos comportamentais, desenvolver uma camada de inteligência territorial em torno dos painéis.

Inicialmente foi feito um algoritmo que com o cruzamento das bases de dados do IBGE, painéis, identificar a localização exata do painel, calcular um raio de 10 KM em torno dele, e com isso consolidar as informações demográficas, econômicas e empresariais em torno do painel, estruturando tudo isso de forma comparável e analítica.



Ou seja, com isso podemos saber quantas empresas existem em torno do painel, qual perfil delas, qual segmentos delas, e ainda aplicar todas as classificações que criamos, entender o potencial na região, saber quais empresas dos segmentos que mais atendemos existem na região, ajudar a enxergar todo o potencial que ainda podemos explorar.

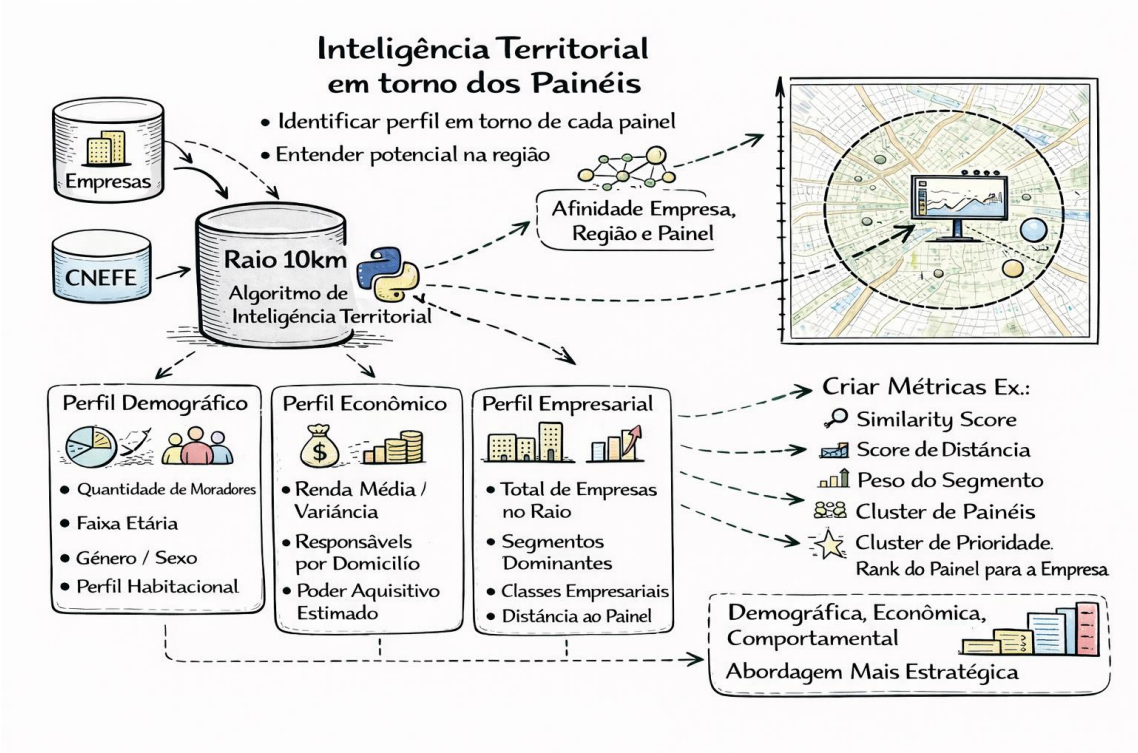
Com isso temos o Perfil demográfico, quantidade de moradores da região, distribuição por faixa etária, Sexo, Gênero, Presença de crianças, idosos, densidade populacional, perfil habitacional, casas, apartamentos, condomínios, estruturas improvisas, isso indica o padrão socioeconômico

Também temos um perfil econômico, como renda média, variância da renda, número de responsáveis por domicilio, poder aquisitivo estimado.

Perfil Empresarial, total de empresas no raio, segmentos dominantes, classes empresariais, empresas ativas, distancia das empresas ao painel.

E isso, tudo nos permite a fazer coisas como, tentar entender a afinidade de empresa, região e painel. Começamos a criar métricas como **Similarity Score**, **Score de distância**, **peso do segmento**, **cluster de painéis**, **Cluster de regiões**, **Cluster de prioridade**, **rank do painel para a empresa**.

A ideia é que com isso, entendendo e tendo a **visão demográfica**, **econômica**, **comportamental**, conseguir fazer uma abordagem ainda mais estratégica, com base em informações e dados. E com isso conseguimos responder perguntas como A região é mais adequada para qual tipo de campanha? Segmento? É compatível com educação infantil ou plano de Saúde? Existe saturação de determinado segmento? Existe oportunidades ainda não exploradas? O painel está subutilizado? Existe densidade empresarial alta e pouca ocupação?



Aqui entra mais alguns conceitos novos, como:

Trade Area Analysis: Definição de Area de influência.

Spatial Density Analysis: Analise de concentração empresarial e populacional

Clusterização Geográfica: Agrupar regiões por perfil socioeconômico.

Overlay Analysis: Sobreposição de múltiplas Camadas, sendo demográfica, empresas, histórico, segmento.

E Nisso tudo entra mais **Machine Lerning**, nos possibilitando transformar informações que pareciam ser simples em uma variável estratégica.

E ao invés de por exemplo dizer, Tal painel está em determinado bairro, podemos falar, esse painel está em uma região com alta densidade empresarial, populacional para determinado segmento, com renda média acima da media municipal, forte presença para público alvo com histórico de campanhas similares. Isso tudo com dados da uma visão muito mais ampla.

Esses são apenas alguns exemplos do que é possível fazer com Machine Learning e tudo isso só é possível com um banco de dados estruturado.

A ideia inicial era criar o banco de dados, onde relacionaríamos tudo isso. Porém percebemos que teríamos a necessidade de ter algo onde fosse possível ver essas informações, de forma estruturada, que faça sentido é claro de acordo com o perfil do usuário, porque nem todo mundo pode ver tudo.

As informações precisariam ser exibidas de forma que faça sentido e que permitisse interagir com elas.

Então, como transformar tudo isso em algo simples, útil e pratico? Partindo do principio de que o usuário não precisa se adaptar a ferramenta, se a ferramenta altera

a rotina de forma desconfortável para o usuário, se deixa a experiencia dele ruim, ela simplesmente será ignorada, e se tornara inútil.

Com isso, começamos a criar a aplicação web, ela é uma camada de tradução e exibição dos dados.

Basicamente:

Dado → Informação → Insight → Decisão

Inicialmente a aplicação seria tela de ocupação de faces, visualização de contratos, duração, reserva de espaço, mas conforme os dados evoluíram, ficou evidente que o a rotina e experiencia do usuário poderia ser potencializada.

Logo por exemplo criamos uma pagina onde se pode ver os cadastros das empresas, e nessa pagina tem diversos filtros para auxiliar, e dentro do cadastro da empresa tem diversas informações uteis, como **histórico do cliente**, **cluster**, **score**, **scimilarity Score**, **propensão a fazer negócios**, **potencial**, **perfil econômico**, por exemplo se for cliente da **Euromidia**, dá para ver os painéis compatíveis com o cliente, risco de **churn**, score atualizado diariamente etc...

Criamos pagina para os painéis, onde é possível ver a ocupação, contratos ativos, histórico de rentabilidade, performance, ver a comparação da performance com outros painéis (pode comparar quantos quiser e ao mesmo tempo), comparação com índices econômicos, ver perfil demográfico da região, densidade empresarial, segmentos dominantes para a região, potencial estratégico, e ainda tem diversas outras classificações e informações que foi colocadas, como equipamentos que compõem o painel, ocorrências que ele teve etc...

Um exemplo de situação interessante é o seguinte. Imagina que um vendedor negocia, oferece alternativas, recebe pedido de desconto, perde cliente etc... Poderíamos usar essas ocorrências e criar uma forma estruturada de analisar isso e entender padrões.

Por exemplo, quantas vezes vendas são feitas mediante a desconto? E quanto foi esse desconto? Quanto tempo durou a negociação? Quanto desconto em media é concedido? Quais painéis são mais disputados e quantos ficam mais ociosos? Quais regiões tem mais objeções, quanto tempo leva para fechar uma venda? Quantas recorrências temos? Quais segmentos somos mais pressionados por desconto? Etc... é uma infinidade.

Então surgiu uma ideia, uma possibilidade de fazer isso, seria criar um **kanban**, integrado ao nosso banco de dados SQL Server, onde cada usuário visualiza apenas seus atendimentos e acompanha cada negociação em fases, por exemplo:

Início → Negociação → Concluído (ou Perdido)

Cada atendimento vira um card, dentro desse card o usuário registra o que está acontecendo, as ocorrências. Dentro do card pode por exemplo adicionar o Painel/Face desejada, selecionar o cadastro da empresa, ver a ocupação, registrar pedido de desconto, registrar ocorrências, observações, interagir com o gestor e tudo isso vai sendo registrado no banco de dados. Por exemplo se surgir pedido de desconto, o card sinaliza ao gestor, o gestor tem a visão de todos os cards de todos os usuários, e simplesmente ele consegue ver através de todas as visões criadas o perfil

da empresa, histórico, região, performance, margem envolvida e ajusta o valor de acordo com seus critérios, ao fazer isso a ação é registrada e assim passamos a saber, quanto era o preço original, quanto ficou, percentual de desconto aplicado, quanto tempo levou, quem aprovou, em que contexto foi aprovado e se a negociação foi perdida, a aplicação obriga o usuário a informar o motivo, como preço, concorrência, falta de espaço etc...

Transformando o atendimento em dado estruturado, com o passar do tempo teremos um histórico real e entender como o mercado reage, poderemos identificar padrões, detectar gargalos e com isso os algoritmos que formos criando vão sendo alimentados e treinados com todos esses dados, e vão aprendendo cada vez mais o nosso contexto e ficando mais precisos.